

并行计算 II 2026 春第一次作业

基于 OpenMP 优化直方图统计

王越洋

1 直方图统计算法

直方图统计 (Histogram Computation) 是一种将连续数据离散化统计的基本方法, 广泛应用于图像处理、数据分析和机器学习等领域。给定 N 个浮点数 $x_0, x_1, \dots, x_{N-1}$, 以及值域范围 $[min, max]$ 和区间数 M , 直方图统计的目标是统计每个区间 (bin) 中数据点的个数。

1.1 算法流程

将值域 $[min, max]$ 均匀划分为 M 个宽度相等的区间, 第 k 个区间为 $[min + k \cdot w, min + (k + 1) \cdot w)$, 其中 $w = (max - min) / M$ 。

对于每个数据点 x_i , 计算其所属区间编号并累加计数:

1. 初始化: $hist[k] = 0, k = 0, 1, \dots, M - 1$ 。

2. 对于每个数据点 x_i (i 从 0 到 $N - 1$):

(a) 计算所属区间编号: $bin = \left\lfloor \frac{x_i - min}{w} \right\rfloor$,

(b) 对该区间计数加一: $hist[bin] += 1$ 。

串行算法的时间复杂度为 $O(N)$, 串行代码如下:

```
double bin_width = (max_val - min_val) / M;
for (int i = 0; i < N; ++i) {
    int bin = (int)((data[i] - min_val) / bin_width);
    hist[bin]++;
}
```

1.2 并行化的挑战

数据竞争 (Race Condition) 当多个线程同时执行 $hist[bin]++$ 时, 由于该操作由“读—加—写”三步组成, 多线程并发执行会导致计数丢失。例如, 线程 A 和线程 B 同时读取 $hist[k] = 5$, 各自加 1 后写回 6, 而正确结果应为 7。

解决数据竞争的常见策略包括:

- **原子操作**：使用 `#pragma omp atomic` 保证每次加法的原子性，实现简单但在高竞争时性能较差。
- **线程私有数组 + 归约**：每个线程维护一份私有直方图，并行阶段结束后串行归约，无竞争但内存占用较大。
- **临界区**：使用 `#pragma omp critical`，开销最大，不推荐。

伪共享 (False Sharing) CPU 缓存以缓存行 (Cache Line, 通常 64 字节) 为最小单位读写。若多个线程频繁写入同一缓存行的不同位置 (如相邻的 bin)，即使它们操作的是不同变量，也会导致缓存行在各核之间反复失效和同步，造成显著的性能下降。这一现象称为**伪共享**。

对于线程私有数组方案，若直接使用二维数组 `local_hist[T][M]`，则相邻线程的数组行在内存中紧邻，极易发生伪共享。解决方法是在每行末尾添加填充 (padding)，使不同线程的数据落在不同缓存行上。

2 作业要求

根据附件中给定的直方图统计串行实现 (`serial.cpp`)，使用 OpenMP 进行并行优化。具体要求如下：

- 提供两个输入数据文件 `input1.dat` 和 `input2.dat`，代码需在两个算例下均运行通过。两个算例的参数如下：

文件	N (数据点数)	M (bin 数)	值域	随机种子
<code>input1.dat</code>	10^7 (10M)	256	[0.0, 1.0)	42
<code>input2.dat</code>	10^8 (100M)	256	[0.0, 1.0)	123

输入文件格式：第一行为 `N M min_val max_val`，随后 N 行每行一个浮点数。可使用附件中提供的 `gen_input.py` 自定义参数生成更多测试算例：

```
python gen_input.py <N> <M> <min_val> <max_val> <output_file> [seed]
python gen_input.py          # 不带参数，直接生成默认的两个算例
```

- 可改变数据的读入及存储方式，此部分无需计入耗时。
- 基于教学集群，最多使用 1 个节点，OpenMP 最多使用 16 线程。
- 不限制编程语言、编译选项和编译器版本 (推荐 C/C++ 实现)。
- 提交代码包括 OpenMP 并行代码 / 计时模块 (可多次运行取平均) / 正确性验证 (也可提供 `check.py` 检验结果)，提供与非优化版本的性能加速比较和分析。
- 提交报告中要求说明线程数目、划分方法以及每个线程的任务负载；鼓励对比不同线程数下的加速比，鼓励进行不同数据规模的对比实验。

- 鼓励报告中提供多版本优化（原子操作、线程私有归约、消除伪共享等）的分析和比较，说明哪些策略带来了明显性能收益。
- **拓展题：**结合具体实验数据，分析伪共享对并行直方图性能的影响，并设计实验验证你的结论（提示：可通过控制 padding 大小进行对比）。

3 提交要求和评分标准

- **提交：**将代码和报告打包后发送至邮箱：wangyueyang@stu.pku.edu.cn，邮件主题为”学号-姓名-第一次作业”，截止日期为 5 月 10 日 23:59。
- **评分：**
 - (1) **基本要求：**基于串行实现完成直方图统计的 OpenMP 并程序，代码运行通过，在报告中给出并行划分方法、运行时间和正确性验证。
 - (2) **性能分析：**分析对比优化前后，哪些策略带来了明显性能收益，代码实际加速效果越好分数越高。
 - (3) **其他加分项：**根据报告内容丰富程度、代码质量及拓展题完成情况酌情加分。