

并行计算 II 2026 春第三次作业

CUDA 并行前缀和

王越洋

1 题目

实现一维数组的并行前缀和 (inclusive scan)

$$y_i = \sum_{j=0}^i x_j, \quad i = 0, 1, \dots, N-1.$$

其中 x 和 y 均为长度为 N 的整数数组。

1.1 串行算法

```
y[0] = x[0]
for i = 1 to N-1 do
    y[i] = y[i-1] + x[i]
end for
```

1.2 数据生成

为了便于自动化验证，本作业不使用随机数，而是用确定性公式生成输入：

$$x[i] = (i * 17 + 13) \% 1000$$

学生程序应在 CPU 端或 GPU 端用该公式生成输入数组，不需要提交输入数据文件。

2 作业要求

- 阅读 `serial.cpp`，理解串行前缀和的计算与输出格式。
- 完成 `parallel.cu` 中所有 `/* Fill in your code */` 的位置：
 1. 分配主机端和设备端数组；
 2. 生成输入数组 x ；
 3. 设计并调用 CUDA kernel 完成前缀和；
 4. 将结果拷回主机端；

5. 将结果写入 `scan_N<N>.txt`。

- 必须使用 CUDA C/C++，不允许调用 Thrust、CUB、cuBLAS 等现成并行前缀和库。
- 建议实现方式：每个 block 内用 shared memory 做局部 scan；对每个 block 的块和再做一次 scan；将块偏移量加回各 block 的局部结果。

算例	N	主要考察目的
S	32	正确性 / 截图
M	1000003	非 2 的幂规模 / 自动验证
L	8388608	性能与加速比测量

使用一张 GPU 即可完成所有实验。

3 编译与运行

```
make
./serial 32
./parallel 32
sbatch run.slurm
```

4 自动验证

`verify.py` 会用同样的公式重建参考答案，对结果文件做逐元素比对：

```
python3 verify.py scan_N1000003.txt
# PASS: all 1000003 elements match the reference prefix sum.
```

如有任何不一致，会打印前 10 个差异的下标、实际值与期望值。退出码：0 表示 PASS，1 表示 FAIL，2 表示文件读取错误。

5 提交

提交内容包括：修改后的 `parallel.cu`； $N = 32$ 情况下的运行截图；`verify.py` 验证 $N = 1000003$ 得到 PASS 的截图；算例 L 的串行时间、CUDA 时间和加速比；报告。

邮件标题格式：姓名-学号-第 3 次作业。截止时间为 6 月 30 日。